



Universidad Pedagógica y Tecnológica de Colombia

Especialización en Programación para Ciencia de Datos

Estadística y Análisis Exploratorio de Datos

Juan David Tejedor Medina

Miguel Gerardo Moreno Avendaño

Proyecto No. 2

Consultoría de Datos Empresariales

Análisis Estadístico del Dataset Bank Marketing

Sector Financiero / Bancario

Firma	DataVenture Analytics
Cliente	Institución Bancaria — Sector Financiero
Dataset	Bank Marketing — bank-full.csv
Fuente	UCI Machine Learning Repository
Fecha de entrega	23 de mayo de 2026
Exposición	Sábado 23 de mayo de 2026

Resumen Ejecutivo

El presente informe corresponde al Proyecto No. 2 de la Especialización en Programación para Ciencia de Datos de la UPTC, desarrollado en el marco de la firma consultora DataVenture Analytics. El análisis se realizó sobre el dataset público Bank Marketing (archivo bank-full.csv), proveniente del UCI Machine Learning Repository, el cual contiene 45.211 registros y 17 variables relacionadas con campañas de marketing directo de una institución bancaria portuguesa.

El objetivo central del proyecto fue analizar las características de los clientes y de la campaña que se asocian con una mayor probabilidad de aceptación de un depósito a término (variable objetivo: y). Para ello, se aplicaron herramientas de estadística descriptiva, análisis visual exploratorio, cálculo de probabilidades y un modelo bayesiano Beta-Binomial.

Los hallazgos principales indican que la tasa de aceptación general fue del 11,70%, con importantes diferencias según el canal de contacto, la carga financiera del cliente y el mes de la campaña. El modelo bayesiano actualizó la creencia inicial del 10% a una estimación posterior del 11,70%, con un intervalo de credibilidad del 90% de [11,45%; 11,95%]. Las recomendaciones estratégicas apuntan a mejorar la segmentación de clientes, fortalecer canales efectivos y planificar campañas en meses con mayor tasa de conversión.

1. Introducción y Enfoque del Proyecto

El presente informe se desarrolla en el marco de una consultoría de datos empresariales para la firma DataVenture Analytics. El propósito del proyecto es analizar un conjunto de datos público relacionado con un problema real de negocio, aplicando herramientas de estadística descriptiva, análisis exploratorio de datos e inferencia bayesiana.

El trabajo no se limita a la ejecución de código en R, sino que busca transformar los datos en información útil para la toma de decisiones. Por esta razón, cada resultado estadístico y visual se interpreta en términos del negocio, con el fin de identificar patrones relevantes, comunicar hallazgos de manera clara y proponer recomendaciones accionables para el cliente.

Para este análisis se seleccionó el dataset público Bank Marketing, correspondiente a campañas de marketing directo de una institución bancaria portuguesa. El objetivo empresarial consiste en comprender qué características de los clientes y de la campaña se asocian con una mayor probabilidad de aceptación de un depósito a término.

El informe se estructura en varias etapas: selección y justificación del dataset, propuesta técnica del análisis, clasificación de variables, análisis descriptivo, visualización exploratoria, cálculo de probabilidades, modelo bayesiano Beta-Binomial, hallazgos principales, recomendaciones y limitaciones del estudio.

2. Propuesta Técnica del Equipo

Antes de iniciar el análisis estadístico y exploratorio, el equipo propuso desarrollar una consultoría de datos orientada al sector financiero, tomando como caso de estudio una campaña de marketing directo realizada por una institución bancaria. El propósito del proyecto es analizar el comportamiento de los clientes frente a la oferta de un depósito a término, con el fin de identificar patrones que permitan mejorar la toma de decisiones comerciales.

El análisis se desarrolló a partir del dataset público Bank Marketing, específicamente el archivo bank-full.csv, el cual contiene información histórica de campañas telefónicas realizadas por una entidad bancaria portuguesa. La variable objetivo del dataset es y, que indica si el cliente aceptó o no el producto ofrecido.

La propuesta de análisis se orientó a responder una pregunta de negocio concreta: ¿qué características de los clientes y de la campaña telefónica se asocian con una mayor probabilidad de aceptación de un depósito a término?

Este enfoque es relevante para el cliente porque las campañas comerciales implican recursos humanos, tiempo, infraestructura tecnológica y costos operativos. Por tanto, comprender qué perfiles de clientes tienen mayor probabilidad de aceptación puede ayudar a la empresa a optimizar sus estrategias de contacto, mejorar la segmentación comercial y aumentar la eficiencia de futuras campañas.

El trabajo se desarrolló en varias etapas: carga y revisión inicial del dataset en R, clasificación de variables, estadísticas descriptivas, visualizaciones exploratorias, análisis de probabilidades simples, conjuntas y condicionales, y finalmente un modelo bayesiano Beta-Binomial para actualizar la probabilidad estimada de aceptación.

Desde el punto de vista empresarial, el objetivo no fue únicamente describir los datos, sino convertir los resultados en información útil para la gerencia. Por esta razón, cada hallazgo se interpretó en

términos del negocio y se formularon recomendaciones accionables para mejorar la efectividad de las campañas bancarias.

3. Ficha Técnica del Dataset

Ítem	Descripción
Nombre del dataset	Bank Marketing
Archivo utilizado	bank-full.csv
Fuente	UCI Machine Learning Repository
URL de descarga	https://archive.ics.uci.edu/dataset/222/bank+marketing
Número de filas	45.211 observaciones
Número de columnas	17 variables
Período de los datos	Mayo de 2008 a noviembre de 2010
Sector o dominio	Financiero / Bancario / Marketing directo
Unidad de análisis	Cliente contactado en una campaña bancaria
Variable objetivo	y: indica si el cliente suscribió o no un depósito a término
Tipo de problema	Análisis de efectividad de campaña comercial
Pregunta de negocio	¿Qué características de los clientes y de la campaña telefónica se asocian con mayor probabilidad de aceptación de un depósito a término?

El dataset contiene registros de campañas de marketing directo realizadas por llamadas telefónicas. En algunos casos fue necesario contactar más de una vez al mismo cliente para determinar si aceptaba o no el depósito a término. La variable de salida y es el objetivo de clasificación.

4. Clasificación de Variables del Dataset

Variable	Tipo	Escala	Relevancia para el negocio
age	Discreta	Razón	Permite analizar si la edad del cliente se relaciona con la aceptación del depósito.
job	Nominal	Nominal	Permite segmentar clientes según ocupación y comparar perfiles laborales.
marital	Nominal	Nominal	Ayuda a identificar diferencias de respuesta según estado civil.
education	Ordinal	Ordinal	Permite evaluar si el nivel educativo se relaciona con la aceptación del producto.
default	Nominal/binaria	Nominal	Indica si el cliente tiene crédito en mora, lo cual puede reflejar riesgo financiero.



balance	Continua	Razón	Representa el saldo promedio anual del cliente y su posible capacidad de ahorro.
housing	Nominal/binaria	Nominal	Permite analizar si tener crédito de vivienda influye en la decisión del cliente.
loan	Nominal/binaria	Nominal	Permite evaluar si tener préstamo personal afecta la aceptación del depósito.
contact	Nominal	Nominal	Permite comparar la efectividad de los canales de contacto.
day	Discreta	Intervalo	Ayuda a revisar posibles patrones según el día del mes del contacto.
month	Nominal	Nominal	Permite identificar posibles patrones temporales o estacionales de la campaña.
duration	Continua	Razón	Representa la duración de la llamada y puede reflejar interés del cliente.
campaign	Discreta	Razón	Indica cuántas veces fue contactado el cliente durante la campaña actual.
pdays	Discreta	Razón	Mide los días desde el último contacto previo; -1 indica que no hubo contacto anterior.
previous	Discreta	Razón	Indica el número de contactos previos antes de la campaña actual.
poutcome	Nominal	Nominal	Permite analizar si el resultado de campañas anteriores influye en la aceptación.
y	Nominal/binaria	Nominal	Variable objetivo: indica si el cliente aceptó o no el depósito a término.

4.1. Interpretación General de la Clasificación de Variables

La estructura del dataset es adecuada para el análisis propuesto porque combina información del cliente, información financiera básica, características de la campaña actual y antecedentes de campañas anteriores. Esta combinación permite evaluar la aceptación del depósito desde una perspectiva integral, considerando tanto el perfil del cliente como la forma en que fue contactado.

Las variables numéricas permitirán estudiar distribuciones, medidas de tendencia central, variabilidad y posibles valores atípicos. Las variables categóricas permitirán comparar segmentos de clientes y responder preguntas como: ¿qué ocupaciones aceptan más el depósito?, ¿el canal de contacto influye en la aceptación?, o ¿el resultado de campañas anteriores afecta la probabilidad de conversión?

La variable y conecta todo el análisis con la pregunta central del negocio, ya que clasifica el resultado de la campaña en aceptación o no aceptación del depósito, y será utilizada como variable objetivo para el análisis de probabilidades y el modelo bayesiano Beta-Binomial.

5. Consideraciones sobre Muestreo, Representatividad y Sesgos

5.1. Tipo de Muestreo Probabilístico Recomendado

Si el equipo tuviera que recolectar estos datos desde cero, el tipo de muestreo probabilístico más adecuado sería el muestreo estratificado. Esto se debe a que los clientes bancarios no conforman un

grupo homogéneo, sino que pueden diferenciarse por características como ocupación, edad, nivel educativo, estado civil, tenencia de créditos y saldo promedio.

El muestreo estratificado permitiría dividir la población de clientes en grupos o estratos relevantes y seleccionar aleatoriamente clientes dentro de cada grupo. De esta manera se garantizaría que los principales segmentos del banco estén representados en el estudio y se reduciría el riesgo de que el análisis se concentre únicamente en un tipo específico de cliente.

5.2. ¿El Dataset Disponible es una Muestra o una Población?

El dataset bank-full.csv puede considerarse una muestra histórica de clientes contactados durante campañas específicas, no una población total de todos los clientes del banco. Aunque contiene 45.211 observaciones, los datos corresponden únicamente a clientes incluidos en campañas de marketing directo realizadas entre mayo de 2008 y noviembre de 2010.

Por esta razón, el dataset es representativo de los clientes que fueron contactados en esas campañas, pero no necesariamente representa a todos los clientes del banco ni a todos los clientes del sector financiero. Las conclusiones pueden orientar decisiones sobre campañas similares, pero deben aplicarse con cautela si el banco desea extrapolarlas a otros productos, períodos de tiempo o poblaciones no contactadas previamente.

5.3. Posible Sesgo de Selección

Un posible sesgo de selección del dataset es que solo incluye clientes que fueron contactados durante campañas telefónicas de marketing. Esto significa que quedan por fuera los clientes que nunca fueron seleccionados para la campaña, los que no tenían información de contacto disponible o aquellos que no eran considerados relevantes por el banco en ese momento.

Este sesgo puede afectar las conclusiones porque los clientes incluidos podrían tener características diferentes a las de la base completa de clientes del banco. Además, la variable duration debe interpretarse con cuidado: una llamada más larga puede estar relacionada con mayor interés del cliente, pero esa información solo se conoce después de realizar el contacto.

5.4. Carga y Revisión Inicial del Dataset

Para dar cumplimiento a la primera parte del análisis técnico, se implementó en R un bloque de código orientado a la carga del dataset, revisión de su estructura general, identificación de valores faltantes y construcción de una tabla manual de clasificación de variables. Este proceso permitió verificar que la base bank-full.csv fue cargada correctamente con 45.211 observaciones y 17 variables.

Tabla 1. Resumen de la Carga Inicial del Dataset

Elemento revisado	Resultado
Archivo utilizado	bank-full.csv
Herramienta de análisis	R / Visual Studio Code
Número de observaciones	45.211
Número de variables	17
Variable objetivo	y

Evento de interés	Cliente acepta el depósito a término
Presencia de variables numéricas	Sí
Presencia de variables categóricas	Sí
Uso posterior de los datos	Estadística descriptiva, visualización, probabilidades y modelo bayesiano

La revisión inicial confirma que el dataset es adecuado para el desarrollo del proyecto, ya que contiene suficiente información para analizar la efectividad de una campaña bancaria desde diferentes perspectivas. Permite estudiar el perfil de los clientes mediante variables como edad, ocupación, estado civil, educación y saldo promedio, así como características propias de la campaña como duración de la llamada, número de contactos, canal de comunicación y resultado de campañas previas.

6. Estadísticas Descriptivas de Variables Numéricas

Para esta etapa del análisis se seleccionaron cinco variables numéricas relevantes para el negocio: age, balance, duration, campaign y previous. Estas variables permiten analizar tanto características del cliente como aspectos operativos de la campaña bancaria.

La variable age describe la edad de los clientes contactados; balance representa el saldo promedio anual del cliente en euros; duration indica la duración de la última llamada en segundos; campaign muestra el número de contactos realizados durante la campaña actual; y previous indica el número de contactos realizados antes de esta campaña.

6.1. Tabla de Estadísticas Descriptivas

Tabla 2. Estadísticas Descriptivas de Variables Numéricas

Variable	Media	Mediana	Moda	Desv. Estándar	Varianza	IQR	Asimetría	Curtosis
age	40,94	39	32	10,62	112,76	15	0,68	3,32
balance	1362,27	448	0	3044,77	9.270.598,95	1356	8,36	143,74
duration	258,16	180	124	257,53	66.320,57	216	3,14	21,15
campaign	2,76	2	1	3,10	9,60	2	4,90	42,25
previous	0,58	0	0	2,30	5,31	0	41,85	4509,36

6.2. Interpretación de Medidas de Tendencia Central

La variable age presenta una media de 40,94 años, una mediana de 39 años y una moda de 32 años. Estos valores son relativamente cercanos, lo que indica que la edad de los clientes se concentra principalmente en adultos jóvenes y de mediana edad. Para el banco, esto sugiere que las campañas telefónicas analizadas se dirigieron principalmente a clientes en edades laboralmente activas.

En el caso de balance, la media es de 1.362,27 euros, mientras que la mediana es de 448 euros y la moda es 0. La diferencia entre estos valores muestra que la distribución del saldo está fuertemente influenciada por clientes con saldos muy altos. Desde el punto de vista empresarial, esto indica que la capacidad financiera de los clientes es heterogénea: muchos tienen saldos bajos, pero algunos pocos elevan considerablemente el promedio.

La variable duration tiene una media de 258,16 segundos, una mediana de 180 segundos y una moda de 124 segundos. Esto indica que la mayoría de las llamadas fue relativamente corta, aunque algunas llamadas más largas aumentan el promedio. La variable campaign muestra una media de 2,76 contactos, con mediana de 2 y moda de 1, indicando que la mayoría de los clientes fue contactado pocas veces. Finalmente, previous presenta una media de 0,58, mediana y moda de 0, lo que indica que gran parte de la campaña estuvo dirigida a clientes sin historial reciente de interacción comercial.

6.3. Interpretación de Variabilidad

La variable age presenta una desviación estándar de 10,62 años y un IQR de 15, lo que indica dispersión moderada. La variable balance presenta una desviación estándar de 3.044,77 euros y una

varianza muy alta, confirmando alta dispersión en los saldos. Para la empresa, esto es importante porque indica que no todos los clientes contactados tienen la misma capacidad financiera.

En *duration*, la desviación estándar es de 257,53 segundos —muy cercana a su media—, mostrando que la duración de las llamadas es bastante variable. La variable *campaign* tiene una desviación estándar de 3,10 contactos, superior a su media de 2,76, lo que puede reflejar casos de insistencia comercial excesiva. La variable *previous* tiene un IQR de 0, confirmando que la mayoría de clientes no presentó contactos previos.

6.4. Asimetría y Curtosis

La variable *age* tiene una asimetría de 0,68 (ligera asimetría positiva) y curtosis de 3,32 (distribución cercana a la normal). La variable *balance* presenta asimetría de 8,36 y curtosis de 143,74, indicando una distribución altamente asimétrica con valores extremos. Para el análisis de *balance* resulta más conveniente considerar la mediana y los percentiles.


La variable *duration* tiene asimetría de 3,14 y curtosis de 21,15, evidenciando que la mayoría de llamadas tiene duración baja o moderada, pero existen llamadas excepcionalmente largas. *Campaign* presenta asimetría de 4,90 y curtosis de 42,25, alertando sobre casos donde se contactó demasiadas veces al mismo cliente. La variable *previous* presenta asimetría de 41,85 y curtosis de 4.509,36, valores extremadamente altos derivados de que la mayoría de clientes tiene cero contactos previos.

6.5. Variable con Distribución Teórica Identificada

La variable que más se aproxima a una distribución teórica conocida es *age*, la cual presenta una forma parcialmente similar a una distribución normal. Esto se observa porque la media (40,94) y la mediana (39) son relativamente cercanas, y la asimetría (0,68) es moderada en comparación con las demás variables analizadas. Sin embargo, existe una ligera asimetría positiva hacia edades mayores.

Para el banco, esta distribución es útil porque permite identificar que la campaña se dirigió principalmente a personas en edad laboral activa. En contraste, variables como *balance*, *duration*, *campaign* y *previous* no se aproximan a una distribución normal, debido a su alta asimetría y curtosis; deben analizarse con medidas robustas como la mediana y el rango intercuartílico.

Distribución de la edad de los clientes



6.6. Conclusión del Análisis Descriptivo

El análisis descriptivo muestra que el dataset contiene variables con comportamientos muy diferentes. La edad de los clientes presenta una distribución relativamente equilibrada, mientras que variables como saldo promedio, duración de llamada, número de contactos y contactos previos muestran alta asimetría y presencia de valores extremos.

Desde el punto de vista empresarial, estos resultados sugieren que el banco no debería interpretar a todos los clientes como un grupo homogéneo. Las futuras campañas podrían beneficiarse de una segmentación más precisa, priorizando perfiles con mayor probabilidad de aceptación y controlando la frecuencia de contacto.

7. Análisis de Probabilidades, FDA y Esperanza Matemática

Para esta sección se seleccionó como variable binaria principal y , la cual indica si el cliente aceptó o no la suscripción a un depósito a término. El evento de interés es $y = \text{yes}$ (el cliente aceptó el depósito a término). Este análisis permite medir la efectividad general de la campaña y comparar la probabilidad de aceptación entre diferentes condiciones del cliente.

7.1. Probabilidades Simples

La probabilidad simple se calculó a partir de la proporción de clientes que aceptaron o no el depósito a término dentro del total de registros analizados.

Tabla 3. Probabilidades Simples de la Variable Objetivo

Evento	Variable	Probabilidad	Porcentaje
Cliente no acepta el depósito	$y = \text{no}$	0,8830	88,30%
Cliente acepta el depósito	$y = \text{yes}$	0,1170	11,70%

La probabilidad de aceptación general fue de aproximadamente 11,70%, mientras que la probabilidad de no aceptación fue de 88,30%. Esto indica que de cada 100 clientes contactados, aproximadamente 12 aceptaron el depósito a término. Desde el punto de vista del negocio, esta tasa de conversión muestra que la campaña tiene un margen importante de mejora.

7.2. Probabilidades Conjuntas

Se calcularon probabilidades conjuntas entre el tipo de contacto utilizado y el resultado de la campaña. La probabilidad conjunta permite responder preguntas como: ¿cuál es la probabilidad de que un cliente haya sido contactado por un canal específico y además haya aceptado o no el depósito? Este análisis permite observar qué combinaciones de canal y resultado fueron más frecuentes, ayudando a identificar si las aceptaciones se concentran en un canal específico.

7.3. Probabilidades Condicionales

Se calcularon probabilidades condicionales para evaluar la aceptación del depósito según diferentes características del cliente y de la campaña.

Tabla 4. Probabilidades Condicionales de Aceptación

Condición	Probabilidad condicional $P(y=\text{yes} \text{condición})$	Porcentaje
Canal de contacto: Celular	$P(y=\text{yes} \text{cellular})$	14,92%
Canal de contacto: Teléfono	$P(y=\text{yes} \text{telephone})$	13,42%
Canal de contacto: Desconocido	$P(y=\text{yes} \text{unknown})$	4,07%
Sin crédito de vivienda	$P(y=\text{yes} \text{housing}=\text{no})$	16,70%
Con crédito de vivienda	$P(y=\text{yes} \text{housing}=\text{yes})$	7,70%
Sin préstamo personal	$P(y=\text{yes} \text{loan}=\text{no})$	12,66%

Con préstamo personal

$P(y=\text{yes} \mid \text{loan}=\text{yes})$

6,68%

La probabilidad condicional permite comparar la efectividad de los canales de contacto. El canal celular presenta una mayor probabilidad de aceptación (14,92%) frente al teléfono tradicional (13,42%) y el contacto desconocido (4,07%). Asimismo, los clientes sin crédito de vivienda muestran una aceptación del 16,70%, más del doble que los clientes con crédito de vivienda (7,70%). De forma similar, los clientes sin préstamo personal presentan mayor aceptación (12,66%) frente a los que tienen préstamo personal (6,68%).

7.4. Función de Distribución Acumulada (FDA)


Para la función de distribución acumulada se seleccionó la variable duration, que representa la duración de la última llamada en segundos. La FDA empírica permite calcular la probabilidad de que una llamada dure hasta cierto número de segundos.

Tabla 5. FDA Empírica de la Duración de Llamadas

Punto de corte	Interpretación	$P(\text{duration} \leq x)$	% Acumulado
120 segundos	Llamadas de máximo 2 minutos	0,3106	31,06%
300 segundos	Llamadas de máximo 5 minutos	0,7285	72,85%
600 segundos	Llamadas de máximo 10 minutos	0,9162	91,62%

La FDA muestra que el 31,06% de las llamadas duró 2 minutos o menos, el 72,85% duró 5 minutos o menos y el 91,62% duró 10 minutos o menos. Esta información ayuda a planificar los tiempos del equipo comercial y a estimar cargas de trabajo y metas realistas de contacto.

Figura 1. FDA Empírica de la Duración de Llamadas (generada en R con ggplot2)



7.5. Esperanza Matemática $E[X]$

La esperanza matemática se calculó para tres variables relevantes. La variable `evento_aceptacion` se construyó asignando el valor 1 a los clientes que aceptaron el depósito y 0 a quienes no lo aceptaron.

Tabla 6. Esperanza Matemática de Variables Relevantes

Variable	Interpretación empresarial	$E[X]$	Unidad
duration	Duración promedio esperada de una llamada	258,16	segundos
balance	Saldo promedio esperado de un cliente	1.362,27	euros
evento_aceptacion	Tasa esperada de aceptación del depósito	0,1170	proporción

La esperanza de `duration` indica que la duración promedio esperada de una llamada es de aproximadamente 258,16 segundos (4,3 minutos). La esperanza de `balance` indica que el saldo promedio esperado de los clientes contactados es de aproximadamente 1.362,27 euros, aunque debe interpretarse con cuidado dado su alta asimetría. Finalmente, la esperanza de `evento_aceptacion` corresponde a 0,1170, equivalente al 11,70% de tasa de aceptación esperada.

7.6. Conclusión del Análisis de Probabilidades

El análisis de probabilidades muestra que la aceptación general del depósito a término es relativamente baja frente al total de clientes contactados. Sin embargo, al analizar probabilidades condicionales, la empresa puede identificar diferencias importantes según el canal de contacto y las



Uptc
Universidad Pedagógica y
Tecnológica de Colombia

**Somos
Todos**

u p t c . e d u . c o

TUNJA - DUITAMA - SOGAMOSO - CHIQUINQUIRÁ

características financieras del cliente. En lugar de evaluar únicamente la tasa global, el banco puede analizar bajo qué condiciones aumenta o disminuye la probabilidad de conversión.

8. Análisis Visual Exploratorio

El análisis visual exploratorio permite identificar patrones, relaciones y diferencias entre segmentos de clientes antes de formular conclusiones o recomendaciones. Las gráficas se construyeron con el propósito de comprender mejor la efectividad de la campaña bancaria, especialmente en relación con la duración de las llamadas, la aceptación del depósito, el saldo promedio de los clientes y posibles patrones temporales.

Tabla 7. Resumen de Visualizaciones Exploratorias

#	Gráfica	Variables utilizadas	Propósito en el negocio
1	Histograma + densidad KDE	duration	Conocer cómo se distribuye la duración de las llamadas y evaluar si la mayoría de contactos son breves o prolongados.
2	Boxplot por categoría	duration + y	Comparar la duración de llamadas entre clientes que aceptaron y no aceptaron el depósito.
3	Gráfica de barras	y	Observar la tasa general de aceptación y rechazo de la campaña.
4	Diagrama de dispersión	age + balance	Analizar si existe relación visual entre la edad del cliente y su saldo promedio anual.
5	Tasa de aceptación por mes (libre)	month + y	Evaluar en qué meses la campaña tuvo mayor proporción de aceptación.


8.1. Gráfica 1: Distribución de la Duración de las Llamadas

Tipo de gráfica: Histograma con densidad KDE | Variable: duration (segundos)

Figura 1. Distribución de la duración de las llamadas (Histograma + KDE).

Distribución de la duración de las llamadas

Histograma con curva de densidad KDE




La gráfica muestra que la duración de las llamadas presenta una distribución asimétrica hacia la derecha. La mayoría de los contactos telefónicos se concentran en duraciones bajas o moderadas, mientras que existe una menor proporción de llamadas con tiempos mucho más prolongados. Desde el punto de vista del negocio, gran parte de las interacciones comerciales fueron relativamente cortas, lo que puede reflejar clientes con bajo interés o contactos en los que no se logró desarrollar una conversación comercial extensa. Sin embargo, las llamadas más largas pueden representar oportunidades de mayor interacción y potencial conversión.

8.2. Gráfica 2: Duración de Llamadas según Aceptación del Depósito

Tipo de gráfica: Boxplot por categoría | Variable cuantitativa: duration | Variable categórica: y

Figura 2. Duración de llamadas según aceptación del depósito (Boxplot).




El boxplot compara la duración de las llamadas entre los clientes que aceptaron el depósito y los que no lo aceptaron. Se observa que las llamadas asociadas a clientes que aceptaron el producto tienden a tener una duración mayor que aquellas de clientes que no aceptaron. Este patrón sugiere que una mayor duración de la llamada puede estar relacionada con una mayor probabilidad de conversión, lo que evidencia la importancia de la calidad de la interacción telefónica.

8.3. Gráfica 3: Proporción de Aceptación del Depósito a Término

Tipo de gráfica: Gráfica de barras | Variable analizada: y

Figura 3. Proporción de aceptación del depósito a término (Gráfica de barras).




La gráfica muestra que el 88,3% de los clientes no aceptó el depósito a término, mientras que el 11,7% sí lo aceptó. Aproximadamente 12 de cada 100 clientes contactados aceptaron el producto, lo que sugiere que existe una oportunidad importante para mejorar la selección de clientes, los canales de contacto y la estrategia comercial.

8.4. Gráfica 4: Relación entre Edad y Saldo Promedio Anual

Tipo de gráfica: Diagrama de dispersión | Variables analizadas: age y balance

Figura 4. Relación entre edad del cliente y saldo promedio anual (Diagrama de dispersión).




El diagrama de dispersión muestra la relación entre la edad del cliente y su saldo promedio anual. Se observa gran dispersión en clientes adultos, indicando que el saldo promedio varía considerablemente entre personas de edades similares. La línea de tendencia muestra una relación levemente positiva entre edad y saldo promedio. Para el banco, esto indica que la segmentación comercial no debería basarse únicamente en la edad.

8.5. Gráfica 5: Tasa de Aceptación del Depósito por Mes

Tipo de gráfica: Gráfica libre | Variables analizadas: mes y tasa de aceptación

Figura 5. Tasa de aceptación del depósito por mes (Gráfica libre horizontal).



La gráfica libre muestra la tasa de aceptación del depósito según el mes en que se realizó el contacto. Se observa que marzo (52,0%), diciembre (46,7%), septiembre (46,5%) y octubre (43,8%) presentan tasas de aceptación considerablemente más altas, mientras que mayo (6,7%), julio (9,1%) y enero (10,1%) presentan tasas más bajas. Este resultado puede ser útil para la planeación comercial, reforzando esfuerzos en los meses con mayor probabilidad de conversión.

8.6. Conclusión del Análisis Visual Exploratorio

El análisis visual exploratorio permitió identificar patrones importantes para la toma de decisiones. La duración de las llamadas presenta una distribución asimétrica; las llamadas de clientes que aceptaron el depósito tienden a ser más prolongadas. La tasa general de aceptación es baja (11,7%), evidenciando la necesidad de mejorar la segmentación. La relación entre edad y saldo promedio muestra alta dispersión. Finalmente, existen variaciones estacionales importantes en la tasa de aceptación que pueden orientar la planeación de futuras campañas.

9. Inferencia Bayesiana Beta-Binomial

El análisis bayesiano se utilizó para actualizar la creencia inicial sobre la probabilidad de que un cliente acepte el depósito a término, a partir de la evidencia observada en el dataset. El evento de interés fue $y = \text{yes}$ (el cliente acepta el depósito a término) y el parámetro θ representa la probabilidad de aceptación.

9.1. Definición de la Distribución A Priori

Antes de observar los datos, se asumió que el banco tenía una creencia inicial de que la tasa de aceptación del depósito era baja, cercana al 10%. Esta creencia se representó mediante una distribución:

A priori: Beta(2, 18) — Media a priori = 0,10 (10%)

Desde el punto de vista del negocio, esta creencia inicial es razonable porque en campañas telefónicas masivas suele esperarse que la mayoría de los clientes no acepte el producto ofrecido.

9.2. Evidencia Observada en los Datos

Tabla 8. Evidencia Observada en el Dataset

Elemento	Resultado
Total de observaciones (n)	45.211
Clientes que aceptaron el depósito (k)	5.289
Clientes que no aceptaron el depósito (n-k)	39.922
Proporción observada de aceptación	0,1170 (11,70%)

9.3. Distribución A Posteriori

Al combinar la creencia inicial con la evidencia observada, se obtuvo la siguiente distribución posterior:

Tabla 9. Comparación A Priori vs. A Posteriori

Distribución	Alpha (α)	Beta (β)	Media	Media %
A priori	2	18	0,1000	10,00%
A posteriori	5.291	39.940	0,1170	11,70%

A posteriori: Beta(5.291, 39.940) — Media posterior = 0,1170 (11,70%)


9.4. Intervalo de Credibilidad del 90%

IC 90% = [11,45% ; 11,95%]

Esto significa que, según el modelo bayesiano, existe un 90% de probabilidad posterior de que la verdadera tasa de aceptación del depósito se encuentre entre 11,45% y 11,95%. En términos prácticos, el banco puede esperar que la aceptación de futuras campañas similares se ubique aproximadamente entre 11 y 12 clientes por cada 100 contactados.

9.5. Gráfica de Actualización Bayesiana

Figura 6. Actualización bayesiana de la probabilidad de aceptación.



La gráfica compara la distribución a priori con la distribución a posteriori. La distribución posterior es mucho más estrecha y concentrada alrededor del 11,70%, porque el tamaño del dataset es grande y la evidencia observada tiene mucho peso en la actualización bayesiana. Esta gráfica muestra que la incertidumbre sobre la tasa de aceptación disminuye considerablemente después de analizar los datos.

9.6. Conclusión del Análisis Bayesiano

El modelo bayesiano permitió actualizar una creencia inicial del 10% de aceptación con base en la evidencia real del dataset. La media posterior de 11,70% indica que la campaña tuvo un desempeño ligeramente superior a la expectativa inicial. El intervalo de credibilidad del 90% [11,45%; 11,95%] ofrece a la empresa un rango confiable para estimar la aceptación esperada en campañas similares.

10. Interpretación Bayesiana en Lenguaje del Cliente

Antes de analizar el dataset, se asumió que el banco tenía una creencia inicial conservadora: la tasa de aceptación esperada del depósito era aproximadamente del 10%, representada mediante una distribución Beta(2,18). Después de analizar los 45.211 clientes contactados, de los cuales 5.289 aceptaron el depósito a término, la estimación bayesiana actualizada ubicó la probabilidad de aceptación en 11,70%, con un intervalo de credibilidad del 90% entre 11,45% y 11,95%.

10.1. Comparación entre Media A Priori y Media A Posteriori

Distribución	Alpha	Beta	Media	Interpretación
A priori	2	18	10,00%	Creencia inicial
A posteriori	5.291	39.940	11,70%	Estimación actualizada

La comparación entre la media a priori y la media a posteriori muestra que los datos modificaron la creencia inicial del banco de forma moderada. Inicialmente se esperaba una tasa de aceptación cercana al 10%, pero la evidencia real mostró una tasa ligeramente superior, cercana al 11,70%. Aunque la diferencia no representa un cambio radical, indica que la campaña tuvo un desempeño un poco mejor de lo esperado.

10.2. Intervalo de Credibilidad del 90%

El intervalo de credibilidad del 90% fue IC 90% = [11,45%; 11,95%]. En lenguaje del cliente:

"Antes de ver los datos, el banco creía que la tasa de aceptación del depósito era aproximadamente del 10%. Después de analizar 45.211 clientes contactados, de los cuales 5.289 aceptaron el producto, la estimación actualizada de aceptación es del 11,70%, con un intervalo de credibilidad del 90% entre 11,45% y 11,95%."

10.3. Interpretación Empresarial del Resultado

El resultado bayesiano muestra que la campaña tiene una tasa de conversión baja, pero estable y cuantificable. El banco puede usar el 11,70% como una línea base para evaluar el desempeño de futuras campañas comerciales similares. Si una nueva campaña obtiene una tasa de aceptación claramente superior al intervalo de 11,45% a 11,95%, podría interpretarse como una mejora real en la efectividad comercial. El intervalo de credibilidad permite incorporar la incertidumbre en la toma de decisiones, ofreciendo un rango probable de conversión más realista que una cifra puntual.

11. Hallazgos Principales en Lenguaje No Técnico

A partir del análisis estadístico, visual y bayesiano realizado sobre el dataset Bank Marketing, se identificaron cinco hallazgos relevantes para la toma de decisiones del banco.

11.1. La Campaña Logra Conversiones, pero la Aceptación General es Baja

El análisis de probabilidades mostró que solo el 11,70% de los clientes contactados aceptó el depósito a término, mientras que el 88,30% no lo aceptó. En términos de negocio, aproximadamente 12 de cada 100 clientes contactados aceptan el producto. El banco no debería depender únicamente de

campañas telefónicas masivas, sino mejorar la segmentación para contactar clientes con mayor probabilidad de respuesta positiva.

11.2. El Canal de Contacto Puede Marcar una Diferencia Importante

El análisis de probabilidades condicionales mostró que la aceptación fue mayor cuando el contacto se realizó por celular (14,92%). En cambio, los contactos clasificados como unknown tuvieron una aceptación de solo 4,07%. Para el banco, esto indica que la calidad y claridad del canal de contacto es importante y que la empresa debería fortalecer la actualización de datos de contacto y priorizar canales con mejor desempeño.

11.3. Los Clientes con Menor Carga Financiera Muestran Mayor Disposición

Los clientes sin crédito de vivienda tuvieron una aceptación de 16,70%, frente a 7,70% en clientes con crédito de vivienda. De manera similar, los clientes sin préstamo personal tuvieron una aceptación de 12,66%, frente a 6,68% en clientes con préstamo personal. Esto sugiere que los clientes con menos compromisos financieros pueden tener mayor capacidad o disposición para contratar un depósito a término.

11.4. Las Llamadas más Largas Parecen Asociarse con Mayor Interés del Cliente

El boxplot de duración de llamadas mostró que los clientes que aceptaron el producto tienden a presentar llamadas más largas. La duración promedio fue de 258,16 segundos (4,3 minutos). Las conversaciones más extensas pueden reflejar mayor interés y mejor oportunidad para explicar el producto. Sin embargo, la duración de la llamada no debe usarse para decidir previamente a quién contactar, sino para evaluar la calidad de la interacción comercial.

11.5. Existen Meses con Mejor Desempeño Comercial

La gráfica de tasa de aceptación por mes mostró diferencias importantes entre períodos. Meses como marzo (52,0%), diciembre (46,7%), septiembre (46,5%) y octubre (43,8%) presentaron tasas de aceptación muy superiores al promedio, mientras que meses como mayo (6,7%) y julio (9,1%) tuvieron menor desempeño. El banco podría revisar qué condiciones estaban presentes en los meses con mejores resultados para planificar futuras campañas.

12. Recomendaciones Estratégicas para el Cliente

Con base en los resultados estadísticos, visuales y bayesianos del análisis, se proponen las siguientes acciones concretas para mejorar la efectividad de futuras campañas de marketing bancario.

12.1. Priorizar Clientes con Mayor Probabilidad de Aceptación

El banco debería implementar una estrategia de segmentación previa a la campaña, priorizando clientes con características asociadas a mayor probabilidad de aceptación del depósito a término. La tasa general fue del 11,70%, pero los clientes sin crédito de vivienda aceptan a una tasa del 16,70% y los clientes sin préstamo personal al 12,66%. Esto sugiere que los clientes con menor carga financiera son un segmento prioritario.

Datos adicionales útiles: ingresos mensuales, capacidad de ahorro, historial de productos contratados, nivel de endeudamiento, perfil de riesgo y antigüedad del cliente en el banco.

12.2. Fortalecer los Canales de Contacto más Efectivos

El banco debería priorizar los canales de contacto que presentan mayor efectividad comercial, especialmente el contacto por celular (14,92%), y al mismo tiempo mejorar la calidad de los registros clasificados como unknown (4,07%). Esto implica actualizar bases de datos, depurar información de contacto y reducir la proporción de clientes con canal desconocido.

Datos adicionales útiles: costo por canal, horario de contacto, tasa de respuesta, número de intentos fallidos, canal preferido por el cliente y resultados de campañas digitales.

12.3. Mejorar la Calidad de la Interacción Telefónica

El banco debería fortalecer la capacitación del equipo comercial para mejorar la calidad de las conversaciones telefónicas. El análisis visual mostró que las llamadas de los clientes que aceptaron el depósito tienden a ser más largas (duración promedio de 258,16 segundos). Una conversación más completa permite explicar mejor el producto, resolver dudas y generar confianza.

Datos adicionales útiles: guion comercial utilizado, experiencia del asesor, horario de la llamada, motivo de rechazo y número de preguntas realizadas.

12.4. Planificar Campañas Considerando los Meses con Mejor Desempeño

El banco debería revisar la planeación temporal de sus campañas, teniendo en cuenta que meses como marzo, diciembre, septiembre y octubre presentaron tasas de aceptación superiores al promedio general. Esto no significa realizar campañas únicamente en esos meses, pero sí analizar qué condiciones favorecen una mayor conversión en esos períodos.

Datos adicionales útiles: promociones vigentes en cada mes, metas comerciales, contexto económico, tasas de interés del producto y comportamiento estacional de los clientes.

12.5. Usar la Tasa Bayesiana como Línea Base para Futuras Campañas

El banco debería utilizar la estimación bayesiana de aceptación como una línea base para comparar el desempeño de nuevas campañas. La tasa posterior estimada fue de 11,70%, con un intervalo de credibilidad del 90% entre 11,45% y 11,95%. Si una futura campaña supera claramente este rango, podría interpretarse como una mejora real en la efectividad comercial.

Tabla 10. Síntesis de Recomendaciones Estratégicas

Recomendación	Acción concreta	Evidencia que la respalda	Datos adicionales requeridos
Segmentar clientes	Priorizar clientes sin créditos activos	Sin vivienda: 16,70%; sin préstamo: 12,66%	Ingresos, endeudamiento, historial
Fortalecer canales	Priorizar celular; depurar unknown	Celular: 14,92%; unknown: 4,07%	Costo canal, canal preferido
Capacitar equipo	Mejorar calidad de la interacción telefónica	Llamadas exitosas son más largas (>258 seg)	Guion, motivo de rechazo, asesor
Temporalidad de campañas	Reforzar en meses con mejor desempeño	Marzo: 52%; dic: 46,7%; sep: 46,5%	Contexto económico, promociones
Usar línea base bayesiana	Comparar futuras campañas contra 11,70%	IC 90%: [11,45%; 11,95%]	Resultados futuros, costos, rentabilidad

13. Limitaciones del Análisis y Supuestos

Todo análisis de datos debe reconocer sus limitaciones para evitar conclusiones exageradas o decisiones basadas en supuestos no verificados. A continuación se presentan las principales limitaciones del dataset y los supuestos realizados durante el análisis.

13.1. Limitaciones del Dataset

Tabla 11. Limitaciones del Dataset

Limitación	Descripción	Posible efecto
Cobertura limitada de la población	Solo incluye clientes contactados en campañas telefónicas de marketing	Las conclusiones representan principalmente a clientes contactados, no a toda la base del banco
Contexto temporal específico	Datos de 2008–2010 en institución bancaria portuguesa	Los resultados pueden no comportarse igual en otros años, países o contextos económicos
Posible sesgo de selección	El banco pudo haber priorizado ciertos clientes según criterios internos no incluidos	La tasa de aceptación observada podría no reflejar la probabilidad real en toda la población
Variable duration post-contacto	La duración de la llamada solo se conoce una vez realizada la llamada	No debe usarse para decidir previamente a quién contactar
Categorías 'unknown'	Algunas variables contienen categorías 'unknown' que ocultan información incompleta	Puede afectar la interpretación de variables como canal de contacto o educación

13.2. Supuestos Realizados Durante el Análisis

Tabla 12. Supuestos del Análisis

Supuesto	Descripción	Posible efecto si no se cumple
Independencia de registros	Cada registro representa una observación independiente dentro de la campaña	Si existen dependencias entre registros, algunas probabilidades podrían estar sesgadas
Calidad de la variable objetivo	La variable y registra correctamente si el cliente aceptó o no el depósito	Errores en esta variable afectarían directamente la tasa de conversión y el modelo bayesiano
Representatividad para campañas similares	Los datos pueden orientar decisiones sobre campañas bancarias similares	Si las condiciones comerciales cambian mucho, las recomendaciones podrían no aplicar directamente
Estabilidad del comportamiento del cliente	Los patrones observados pueden servir como referencia para futuras campañas	Cambios en economía, tasas de interés o preferencias pueden modificar la probabilidad de aceptación



13.3. Conclusión del Punto 13

El análisis realizado ofrece información valiosa para mejorar la toma de decisiones en campañas bancarias, pero sus resultados deben interpretarse con prudencia. La principal limitación es que el dataset no representa necesariamente a todos los clientes del banco, sino únicamente a aquellos incluidos en campañas telefónicas. El contexto temporal y geográfico también debe considerarse: datos de Portugal entre 2008 y 2010 pueden no aplicarse directamente a otros países o períodos económicos.

En términos prácticos, el análisis debe verse como una base inicial para mejorar la segmentación, optimizar canales de contacto y evaluar la efectividad de campañas futuras. Antes de aplicar las recomendaciones a gran escala, sería recomendable complementar el dataset con información adicional como ingresos, historial de productos, rentabilidad del cliente, costos por canal, motivo de rechazo y resultados de campañas más recientes.

14. Conclusión General

El presente informe de consultoría, desarrollado por el equipo de DataVenture Analytics para la Especialización en Programación para Ciencia de Datos de la UPTC, demuestra que el análisis estadístico riguroso puede transformar datos históricos de campañas bancarias en información estratégica de valor para la gerencia.

El análisis del dataset Bank Marketing reveló que la tasa de aceptación del depósito a término fue del 11,70%, con importantes variaciones según el canal de contacto, la carga financiera del cliente y el período de la campaña. El modelo bayesiano Beta-Binomial actualizó la creencia inicial del 10% a una estimación posterior del 11,70%, con un intervalo de credibilidad del 90% de [11,45%; 11,95%], proporcionando una línea base cuantitativa y objetiva para comparar el desempeño de futuras campañas.

Los hallazgos clave muestran que: (1) el canal celular es significativamente más efectivo que los canales desconocidos; (2) los clientes sin compromisos financieros activos muestran mayor disposición al ahorro; (3) las conversaciones más prolongadas se asocian con mayor conversión; y (4) existen patrones temporales claros que pueden orientar la planeación comercial.

Las recomendaciones estratégicas apuntan a que el banco transite de una estrategia de campañas masivas a un enfoque más segmentado, medible y basado en evidencia. La combinación de estadística descriptiva, análisis de probabilidades, visualización exploratoria e inferencia bayesiana proporciona una visión integral que puede contribuir a incrementar la eficiencia comercial y la tasa de conversión del depósito a término en futuras campañas.

Referencias

Moro, S., Cortez, P., & Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. *Decision Support Systems*, 62, 22-31.

UCI Machine Learning Repository. (2014). Bank Marketing Data Set. Recuperado de: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

R Core Team. (2024). R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing. <https://www.R-project.org/>

UPTC — Universidad Pedagógica y Tecnológica de Colombia. (2026). Proyecto No. 2: Consultoría de Datos Empresariales. Estadística y Análisis Exploratorio de Datos. Especialización en Programación para Ciencia de Datos.